RESUMEN EJECUTIVO · ESTUDIO FINALIZADO

Una red pequeña, grafos mucho mayores

Counterfactual añade ejemplos modificados para enseñar a rechazar conflictos. Con este método, la configuración principal mantuvo la corrección al pasar de **40 a 40.960 nodos**: grafos 1.024 veces mayores. [1] [2]

Problema: asignar colores de modo que dos nodos vecinos tengan colores distintos.

61.600/61.600	80	1.024×
coloraciones correctas en el tratamiento principal	réplicas principales 20 por cada grado	aumento del tamaño del grafo evaluado

La ventaja aumenta con el grado

Prueba en 40.960 nodos, tras 120 ciclos de entrenamiento (época 120). Se comparan modelos emparejados. [2] [3]

Vecinos máx. (Δ)	Counterfactual con ejemplos modificados	Own-only solo propuestas propias	Éxito del control
3	**400/400**	390/400	97,5%
5	**400/400**	330/400	82,5%
8	**400/400**	172/400	43%
10	**400/400**	98/400	24,5%

Cada fila reúne 20 modelos × 20 grafos compartidos: diez regulares y diez irregulares. Son 400 ejecuciones, no 400 grafos independientes.

- **Resultado principal.** Cero errores globales y cero confirmaciones inseguras en las 61.600 ejecuciones del tratamiento principal a época 120. [1] [2]
- **La cantidad de datos importa.** Con 200 grafos de entrenamiento y tres ejecuciones por grafo, el éxito en Δ=10 baja a 164/400 (41%). [2]
- **La selección de época importa.** Una época elegida por validación puede fallar en el test, aunque la época 120 del mismo tratamiento funcione. [4] [5]

Alcance de la conclusión. La evidencia respalda alta fiabilidad en las condiciones evaluadas. No demuestra corrección universal. El 100% corresponde al tratamiento principal y a una época fijada antes del test; otras configuraciones registran fallos.

Estudio completo: 565 entrenamientos · 1.210 versiones de pesos · 931.700 evaluaciones. [9]

Cómo se obtuvo la evidencia

Cada nodo aplica la misma red neuronal pequeña y se comunica solo con sus vecinos. Aprende tres decisiones: participar, proponer un color y confirmar o esperar. La ejecución avanza en rondas simultáneas; un color confirmado permanece fijo. Un algoritmo exacto actúa como profesor y genera los ejemplos de aprendizaje. [10]

Qué añade Counterfactual. Enseña a evaluar las propuestas de la propia red y propuestas modificadas deliberadamente para producir conflictos. Las etiquetas indican qué decisión es correcta para la propuesta que realmente se está evaluando. Own-only omite los ejemplos modificados.

Diseño de la comparación principal

Elemento	Condición fijada
Entrenamiento	Desde cero; 800 grafos de 40 nodos, tres ejecuciones aleatorias por grafo, 120 épocas. Las primeras diez usan propuestas del profesor para entrenar la confirmación.
Grados y réplicas	Δ=3, 5, 8 y 10, con Δ+1 colores y 20 semillas por grado. Se entrena un modelo distinto por grado y réplica.
Control emparejado	Mismos datos, inicialización, orden y actualizaciones. A época 120, los módulos de participación, candidato y primera comunicación tienen pesos idénticos en los 80 pares.
Prueba independiente	Seis tamaños: 40, 160, 640, 2.560, 10.240 y 40.960 nodos; familias REGULAR e IRREGULAR. Máximo 256 rondas; mismos grafos y números aleatorios para comparar modelos.

Durante la prueba la red ejecuta sus propias decisiones, sin correcciones del profesor. Las reglas exactas solo se usan para registrar diagnósticos. [4] [10]

La mejora está en la corrección; las rondas siguen próximas

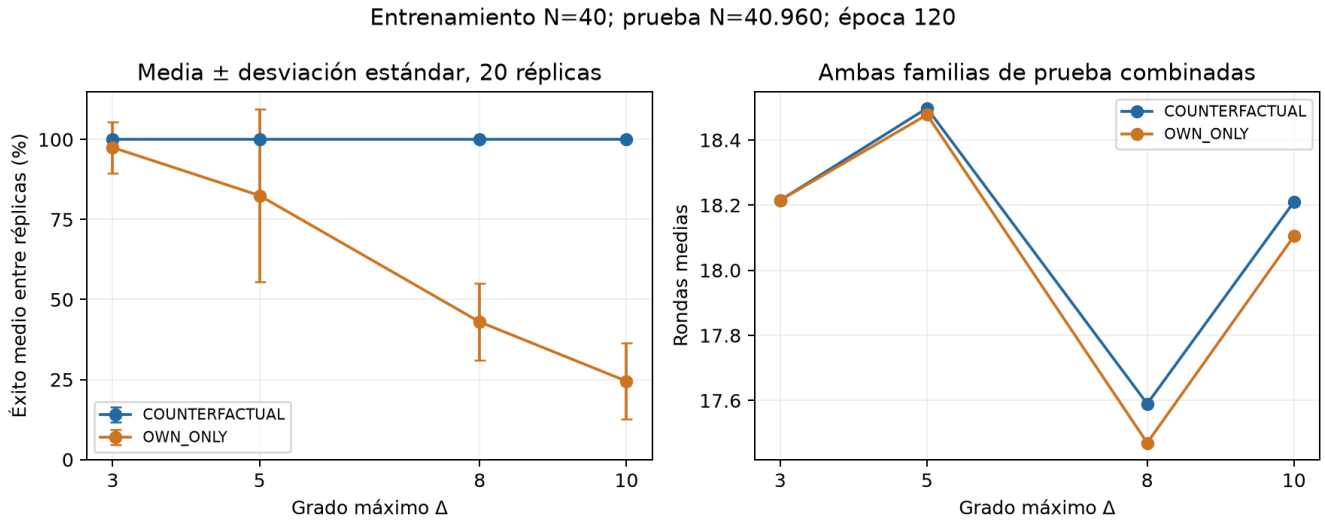


Figura 1. Modelos entrenados en 40 nodos y evaluados en 40.960. Las barras son desviaciones estándar entre 20 réplicas, no intervalos de confianza. Las rondas incluyen ejecuciones incorrectas; terminar rápido con una coloración inválida no mejora el resultado. [2] [6]

Datos y selección de época: dos decisiones que importan

Los presupuestos siguientes se eligieron con validación antes de abrir el test. Cada celda resume 20 réplicas Counterfactual a época 120 y prueba en 40.960 nodos. [2] [4]

	800 × 3 épocas fijas	200 × 3 épocas fijas	2.400 × 1 épocas fijas	800 × 3 30.720 actualiz.
Δ=3	100%	100%	100%	100%
Δ=5	100%	100%	100%	100%
Δ=8	100%	86,25%	99,5%	100%
Δ=10	100%	41%	100%	100%

Figura 2. Grafos de entrenamiento × ejecuciones aleatorias por grafo (tapes). Las columnas de épocas fijas usan 120 épocas. La última fija 256 actualizaciones por época: 30.720 en total.

Hallazgo de presupuesto. Reducir de 800 a 200 grafos con tres tapes conserva el 100% en Δ=3 y Δ=5, pero baja a 345/400 (86,25%) en Δ=8 y a 164/400 (41%) en Δ=10. Con épocas fijas también cambia el número de actualizaciones; el efecto no se atribuye solo a diversidad estructural.

Una buena validación no garantiza una buena época

Se congelaron dos políticas: **best**, que toma la época elegida por validación, y **epoch-120**, la última época común. La validación de selección usa 16 grafos por candidato. En el tratamiento principal, best produjo estos fallos: [4] [5]

Réplica	Época elegida	Fallos en el test
Δ=3, semilla 17	10, aún en la etapa inicial	108/770, incluidos 20/20 en N=40.960
Δ=8, semilla 18	30	1/770, en un grafo regular de 640 nodos

Ambas políticas estaban fijadas antes de evaluar. Se conservan los fallos de best y se informa por separado el resultado de época 120; el test no se usa para reseleccionar modelos.

Grados variados y referencias históricas

Entrenar con **MIXED** (mitad grafos regulares y mitad irregulares) obtiene también 61.600/61.600 a época 120. Como REGULAR ya alcanza ese éxito, el test no distingue una mejora de MIXED en corrección. Su selección best sí registra fallos. [1] [3]

En Δ=3 y con cinco semillas, ORACLE_MATCHED y TRADITIONAL con tres tapes obtienen 100/100 en el tamaño máximo a época 120. TRADITIONAL con un tape obtiene 54/100. Estas referencias muestran sensibilidad al presupuesto, con un alcance menor que la comparación principal. [1] [2]

Cómo interpretar los resultados

Unidad experimental. En el tamaño máximo, cada modelo se prueba en 20 grafos: diez de cada familia. Esos mismos grafos se reutilizan en 20 réplicas. Las 400 ejecuciones por fila ayudan a comparar modelos, pero no amplían la cohorte a 400 grafos nuevos.

Incertidumbre y alcance

• **Muestra de grafos limitada.** Con 10 éxitos de 10 grafos de una familia, el límite inferior del intervalo exacto bilateral del 95% es aproximadamente 69,2%. Observar cero fallos no equivale a garantizar cero fallos futuros. [6]

• **Réplicas y grafos compartidos.** Los intervalos entre semillas condicionan en el conjunto de grafos observado. Las comparaciones emparejadas son exploratorias, sin corrección por multiplicidad. Las 931.700 evaluaciones no se tratan como ensayos independientes. [2] [3]

• **Generalización acotada.** Se verificó aumento de tamaño para modelos separados por grado, en las familias REGULAR e IRREGULAR del protocolo. La comunicación local se simula en un proceso; no se midió un despliegue físicamente distribuido. [4]

Los errores locales no se explican solo por k=1

k es la cantidad de colores aún disponibles. En Own-only, grado 3, las diez confirmaciones inseguras del tamaño máximo aparecen en k=1. En grado 10, 56.646 de 96.781 aparecen en k=11: también importan los conflictos entre propuestas simultáneas. Una decisión contraria a la regla del profesor puede dejar una coloración final válida si el vecino espera; se miden ambas cosas por separado. [7]

Coste observado

Los 565 entrenamientos suman **37,55 horas registradas**, incluida la generación inicial de datos. En la configuración principal, Counterfactual requiere aproximadamente un 19–51% más de tiempo que Own-only, según el grado, aunque iguala sus actualizaciones. Son costes de este entorno, no estimaciones de latencia en una red física. [8]

Preguntas para una siguiente etapa

• **Ampliar la prueba independiente.** Añadir más grafos grandes para estimar mejor la fiabilidad.

• **Revisar la selección de época.** Evaluar, con un protocolo nuevo, validaciones más amplias y reglas que distingan la etapa inicial de entrenamiento.

• **Separar mecanismos de error.** Estudiar disponibilidad de colores y conflictos simultáneos en ablaciones nuevas; conservar intactos el protocolo y el test de este estudio.

Referencias y trazabilidad

Los números entre corchetes del informe llevan a esta guía. Cada enlace abre la versión publicada que respalda la afirmación; las fuentes quedan fijadas al commit del cierre.

[1] Informe científico final

Interpretación completa, resultados negativos y límites.

ANALISIS.md

[2] Resultados principales y variación entre semillas

Éxito por grado, tamaño y presupuesto; medianas y bootstrap.

success-summary.csv · seed-summary.csv

[3] Comparaciones emparejadas

Métodos sobre los mismos grafos y tapes; comparación REGULAR / MIXED.

paired-by-seed.csv · structural-paired.csv

[4] Protocolo y decisiones anteriores al test

Selección por validación, presupuestos y congelación de la prueba.

docs/M6VALIDATION.md

[5] Registro de coloraciones incorrectas

Identifica réplica, época, grafo y resultado de cada fallo.

errors.csv

[6] Intervalos, rondas y tiempos por semilla

Denominadores por familia/tamaño e intervalos de confianza.

scientific-success-by-seed.csv

[7] Diagnóstico de errores locales

Estados, propuestas prohibidas y confirmaciones inseguras según k.

k-by-seed.csv

[8] Presupuesto y coste de entrenamiento

Actualizaciones, datos expuestos y tiempo registrado por ejecución.

training.csv

[9] Identidad y cierre del estudio

Modelos incluidos, hashes, cohortes y cierre de los 64 grupos.

snapshot.json · final-report-state.json

[10] Implementación del método

Arquitectura, propuestas contrafactuales y etiquetas concordantes.

m4_models.py · counterfactual.py

Repositorio: github.com/mrioswilson/distributed-coloring-learning
Versión de las fuentes: `d734825051f2958b7a628b60ce4cd0c9ae3003f9`
Fecha de cierre: 17 de octubre de 2026, hora de Chile. Pruebas terminadas a las 22:43; informes automáticos a las 22:55.

Los datos originales por grafo y los checkpoints se conservan en el servidor. GitHub contiene código, tablas, figuras y hashes para revisar la evidencia y su procedencia.